



REGRESSÃO LOGÍSTICA CLASSIFICAÇÃO



Rogério Gomes e Paulo Almeida

Classificação

2

Email: Spam / Não Spam?


Transações Online: Fraudulenta (Sim / Não)?

Tumor: Maligno / Benigno ?

$$y \in \{0, 1\}$$

0: “Classe Negativa” (e.g., tumor benígno)

1: “Classe Positiva” (e.g., tumor malígno)



Limiar de saída do Classificador $h_{\theta}(x)$ em 0.5:

Se $h_{\theta}(x) \geq 0.5$, predizer “y = 1”

Se $h_{\theta}(x) < 0.5$, predizer “y = 0”

Classificação: $y = 0$ ou 1

Mas na regressão linear:

$h_{\theta}(x)$ pode ser > 1 ou < 0

Então usar:

Regressão Logística: $0 \leq h_{\theta}(x) \leq 1$

Regressão Logística


Representação

Modelo : Regressão Logística

$$0 \leq h_{\theta}(x) \leq 1$$

$$h_{\theta}(x) = g(\underbrace{\theta^T x}_{z})$$

$$g(z) = \frac{1}{1 + e^{-z}}$$



Função Sigmoidal ou
Função Logística

Saída da Hipótese - Interpretação

7

$h_{\theta}(x)$ = probabilidade da saída ser $y = 1$ para uma entrada x

Exemplo: se $x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ \text{tumorSize} \end{bmatrix}$
 $h_{\theta}(x) = 0.7$

O paciente tem 70% de chance de ter um tumor maligno

$h_{\theta}(x) = P(y = 1|x; \theta)$ “probabilidade de $y = 1$, dado x , parametrizado por θ ”

$$P(y = 0|x; \theta) + P(y = 1|x; \theta) = 1$$
$$P(y = 0|x; \theta) = 1 - P(y = 1|x; \theta)$$

Regressão Logística

Fronteira de Decisão

Regressão Logística

9

$$h_{\theta}(x) = g(\theta^T x)$$

$$g(z) = \frac{1}{1+e^{-z}}$$


Suponha: prever “ $y = 1$ ” se $h_{\theta}(x) \geq 0.5$

$$\theta^T X \geq 0 \rightarrow g(z) \geq 0,5$$

$$h_{\theta}(x) = g(\theta^T X)$$


prever “ $y = 0$ ” se $h_{\theta}(x) < 0.5$

$$\theta^T X < 0 \rightarrow g(z) < 0,5$$



Fronteira de Decisão

10



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

Predizer “ $y = 1$ ” se $-3 + x_1 + x_2 \geq 0$
 $x_1 + x_2 \geq 3$

Para $y = 0$ $x_1 + x_2 < 3$

Fazendo



$$h_g(x) = 0,5$$

Temos :

$$x_1 + x_2 = 3$$

Fronteiras de decisão Não-lineares

11



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$$

$$\theta = [-1 \quad 0 \quad 0 \quad 1 \quad 1]$$

Predizer “ $y = 1$ ” se $-1 + x_1^2 + x_2^2 \geq 0$

$$x_1^2 + x_2^2 = 1$$

$$x_1^2 + x_2^2 \geq 1$$

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_1^2 x_2 + \theta_5 x_1^2 x_2^2 + \theta_6 x_1^3 x_2 + \dots)$$

Regressão Logística

Função Custo

Conjunto de Treinamento: $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})\}$

m exemplos $x \in \begin{bmatrix} x_0 \\ x_1 \\ \dots \\ x_n \end{bmatrix} \quad x_0 = 1, y \in \{0, 1\}$

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$



Como escolher os parâmetros θ ?

Função Custo

14

Regressão Linear: $J(\theta) = \frac{1}{m} \sum_{i=1}^m \frac{1}{2} (h_{\theta}(x^{(i)}) - y^{(i)})^2$

$$\text{Cost}(h_{\theta}(x^{(i)}), y^{(i)}) = \frac{1}{2} (h_{\theta}(x^{(i)}) - y^{(i)})^2$$




Regressão Logística – Função Custo

15

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

Custo=0 se $y = 1, h_{\theta}(x) = 1$


Mas quando $h_{\theta}(x) \rightarrow 0, \text{Cost} \rightarrow \infty$



Regressão Logística – Função Custo

16

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$



Regressão Logística - Função Custo Simplificada e Gradiente Descendente

Regressão Logística – Função Custo

18

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$$

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

Observe: $y = 0$ ou $y = 1$ Sempre

$$\text{Cost}(h_{\theta}(x), y) = -y \log(h_{\theta}(x)) - (1 - y) \log(1 - h_{\theta}(x))$$

Regressão Logística – Função Custo

19

$$\begin{aligned} J(\theta) &= \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)}) \\ &= -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right] \end{aligned}$$

Para ajustar os parâmetros θ , faça:

$$\min_{\theta} J(\theta)$$

Para prever um novo valor de x :

$$\text{Saída } h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

Gradiente Descendente

20

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right]$$

$$\min_{\theta} J(\theta)$$

Repeat {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

} (simultaneamente atualize todos os θ_j)

$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

Gradiente Descendente

21

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right]$$

$$\min_{\theta} J(\theta)$$

Repeat {

$$\theta_j := \theta_j - \alpha \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

} (simultaneamente atualize todos os θ_j)

O algoritmo parece idêntico à regressão linear!

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

Regressão Logística - Otimização Avançada

Algoritmo de otimização

23

Função Custo $J(\theta)$. Queremos $\min_{\theta} J(\theta)$.

Dado θ , Nós temos que computar

- $J(\theta)$
- $\frac{\partial}{\partial \theta_j} J(\theta)$ (for $j = 0, 1, \dots, n$)

Gradiente descendente:

Repeat {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

}

Algoritmo de otimização

24

Dado θ , temos que computar

- $J(\theta)$
- $\frac{\partial}{\partial \theta_j} J(\theta)$ (for $j = 0, 1, \dots, n$)

Algoritmos de Otimização:

- Gradiente descendente
- Gradiente Conjugado
- BFGS
- L-BFGS

Vantagens:

- Não precisa definir α manualmente
- Usualmente mais rápido que o gradiente descendente.

Desvantagens:

- Mais complexo

Exemplo:

$$\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}$$

$$J(\theta) = (\theta_1 - 5)^2 + (\theta_2 - 5)^2$$

$$\frac{\partial}{\partial \theta_1} J(\theta) = 2(\theta_1 - 5)$$

$$\frac{\partial}{\partial \theta_2} J(\theta) = 2(\theta_2 - 5)$$

```
function [jVal, gradient]
    = costFunction(theta)
    jVal = (theta(1)-5)^2 + ...
          (theta(2)-5)^2;
    gradient = zeros(2,1);
    gradient(1) = 2*(theta(1)-5);
    gradient(2) = 2*(theta(2)-5);
```

```
options = optimset('GradObj', 'on', 'MaxIter', '100');
initialTheta = zeros(2,1);
[optTheta, functionVal, exitFlag] ...
    = fminunc(@costFunction, initialTheta, options);
```

```

theta =  $\begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$ 
function [jVal, gradient] = costFunction(theta)
jVal = [code to compute  $J(\theta)$ ];
gradient(1) = [code to compute  $\frac{\partial}{\partial \theta_0} J(\theta)$ ];
gradient(2) = [code to compute  $\frac{\partial}{\partial \theta_1} J(\theta)$ ];
      ⋮
gradient(n+1) = [code to compute  $\frac{\partial}{\partial \theta_n} J(\theta)$ ];

```

Regressão Logística

Classificação Multi-classes:

Um-vs-todos

Classificação Multiclasses


28

Email foldering/tagging: Work, Friends, Family, Hobby


Medical diagrams: Not ill, Cold, Flu

Weather: Sunny, Cloudy, Rain, Snow


Classificação Binária:



Classificação Multi-classe:



Um-vs-todos (One-vs-all)






Class 1: 

Class 2: 

Class 3: 

$$h_{\theta}^{(i)}(x) = P(y = i | x; \theta) \quad (i = 1, 2, 3)$$



Um-vs-todos (One-vs-all)

Treine o classificador regressão logística $h_{\theta}^{(i)}(x)$ para cada classe i para prever a probabilidade de $y = i$.

Para cada nova entrada x , faça a predição e pegue a classe i que maximiza

$$\max_i h_{\theta}^{(i)}(x)$$